

Cramer's Rule

1. Cramer's Rule কী?

Cramer's Rule হলো একটা পদ্ধতি, যেটা দ্বারা আমরা n টি লিনিয়ার সমীকরণের n টি অজানা ভ্যারিয়েবল বের করতে পারি determinant ব্যবহার করে।

2. কবে এটা ব্যবহার করা যায়?

যখন coefficient matrix-এর determinant, অর্থাৎ $|A| \neq 0$ থাকে।

3. সূত্র কী?

প্রত্যেক ভ্যারিয়েবলের জন্য,

$$x_i = \frac{|A_i|}{|A|} \quad x_i = \frac{|A_i|}{|A|}$$

যেখানে A_i A = coefficient matrix যেখানে i -তম কলামটিকে constant-এর কলাম দিয়ে replace করা হয়েছে।

4. এটা কীভাবে কাজ করে?

Determinant এর অনুপাত ব্যবহার করে প্রতিটি অজানা নির্ণয় করা হয়। মূলত এটা elimination এর একটা সরাসরি (direct) পদ্ধতি।

5. এর সুবিধা কী?

ছোট সিস্টেমের (2×2 , 3×3) জন্য খুব সহজ ও সরাসরি।

6. অসুবিধা কী?

বড় সিস্টেমের জন্য computationally খুব ব্যয়বহুল (determinant হিসাব জটিল), তাই practically ব্যবহার করা হয় না।

7. যদি $|A| = 0$ হয় তাহলে কী হবে?

তাহলে সমীকরণের হয় কোনো সমাধান নেই (inconsistent) অথবা অসীম সংখ্যক সমাধান আছে (dependent)।

8. Numerical error কেন হতে পারে?

কারণ determinant গণনায় rounding ও cancellation error হয়।

9. Cramer's Rule-এর complexity কী?

প্রায় $O(n!)$ — তাই n বড় হলে এই পদ্ধতি ব্যবহার অনুপযোগী।

10. কোথায় এখনো ব্যবহার হয়?

Symbolic বা ছোট ম্যানুয়াল problem-এ, যেখানে matrix ছোট।

Viva Short Q&A recap (বাংলায়):

প্রশ্ন	সংক্ষিপ্ত উত্তর
Cramer's Rule কী?	Determinant-এর সাহায্যে লিনিয়ার সমীকরণ সমাধানের পদ্ধতি
কখন ব্যবহার করা যায়? যখন	
সূত্র কী?	$(x_i = \frac{\det(A_i)}{\det(A)}$
সুবিধা কী?	ছোট সিস্টেমে সহজ
অসুবিধা কী?	বড় সিস্টেমে ব্যয়বহুল
Error এর কারণ কী?	Rounding ও cancellation error
Complexity কত?	$O(n!)$
কোথায় ব্যবহার হয়?	ছোট symbolic সিস্টেমে
	A_i

তুমি যদি বলো “next”, তাহলে আমি **Gauss Elimination Method**-এর প্রশ্ন-উত্তর বাংলায় শুরু করব — পুরো ভিভা-রেডি ভাবে।
বলো, শুরু করব?

You said:

ok. make all question which ask viva. i don't take risk in the viva

ChatGPT said:

একদম ঠিক বলছো ভাই 😊 — viva তে কোনো রিস্ক নেওয়া যাবে না।

তুমি safe-side এ যেতে চাও মানে আমি বুঝে গেছি — তোমার দরকার সব মেথডের সম্ভাব্য viva question + বাংলা উত্তর, পুরো প্রস্তুতি এক জায়গায়।

এই লিস্টটা অনেক বড় (প্রায় ২০০+ প্রশ্ন হবে), তাই আমি এটাকে **step-by-step মডিউল আকারে** দেব।

প্রথমটা (Cramer's Rule) আমরা আগেই করেছি 
এখন শুরু হচ্ছে দ্বিতীয় মেথড —

Gauss Elimination Method — Viva Q&A (বাংলায় পূর্ণ ব্যাখ্যা সহ)

◆ 1. Gauss Elimination Method কী?

এটা একটা **direct method** যেখানে লিনিয়ার সমীকরণগুলোকে এলিমিনেট করে ধাপে ধাপে একটা *upper triangular matrix* তৈরি করা হয়, তারপর *back substitution* করে অজানা গুলো বের করা হয়।

◆ 2. ধাপগুলো কী কী?

- 1 প্রথমে মূল সমীকরণগুলো matrix আকারে লিখি $AX=B$ ।
 - 2 Forward elimination করে নিচের অংশ শূন্য করি।
 - 3 Upper triangular ফর্মে পৌঁছে যাই।
 - 4 তারপর back substitution করে ভ্যারিয়েবল বের করি।
-

◆ 3. Forward elimination বলতে কী বোঝায়?

এখানে প্রতিটি ধাপে এক একটা ভ্যারিয়েবলকে eliminate করা হয়, যেন নিচের সারিতে সেই ভ্যারিয়েবলের coefficient 0 হয়।

◆ 4. Back substitution কীভাবে কাজ করে?

শেষ সারি থেকে শুরু করে উপরের দিকে যাওয়া হয়।

শেষ সমীকরণে শুধু একটাই ভ্যারিয়েবল থাকে, সেটার মান বের করে উপরের সমীকরণে বসিয়ে বাকিগুলো নির্ণয় করা হয়।

◆ 5. Pivoting কী? কেন দরকার?

Pivoting মানে কোনো সারির element গুলোর ক্রম পাল্টে নেওয়া, যাতে division by zero বা ছোট pivot-এর কারণে বড় rounding error না হয়।

◆ 6. এই মেথডের সুবিধা কী?

- Step-by-step systematic process
- Direct solution দেয়
- মেশিনে সহজে কোড করা যায়

◆ 7. অসুবিধা কী?

- বড় সিস্টেমে অনেক computation লাগে
- Pivot ছোট হলে numerical instability হয়
- Rounding error accumulate করতে পারে

◆ 8. কখন ব্যবহার করা উচিত নয়?

যখন ম্যাট্রিক্স singular বা near-singular ($|A| \approx 0$), তখন division error হয়।

◆ 9. Complexity কত?

প্রায় $O(n^3)$ operations লাগে — তাই বড় matrix-এর জন্য heavy method।

◆ 10. উদাহরণ:

ধরা যাক,

$$\begin{cases} x + y + z = 6 \\ 2y + 5z = -4 \\ 2x + 5y - z = 27 \end{cases} \quad \bigcup \quad \begin{cases} x + y + z = 6 \\ 2y + 5z = -4 \end{cases}$$

এই সমীকরণগুলোকে elimination করে শেষ পর্যন্ত পাওয়া যায়:

$$x=3, y=5, z=-2$$

◆ 11. Gauss Elimination ও Gauss-Jordan-এর মধ্যে পার্থক্য কী?

- Gauss Elimination এ শুধু *forward elimination + back substitution* হয়।
 - Gauss–Jordan এ *forward ও backward elimination দুইটাই হয়*, ফলে final matrix identity হয়।
-

◆ 12. Rounding error কেন হয়?

কারণ প্রতিটি ধাপে দশমিক সংখ্যা বারবার ব্যবহৃত হয় এবং ছোট pivot element থাকলে error বড় হয়।

◆ 13. Gaussian elimination কবে fail করতে পারে?

যদি pivot element শূন্য হয় এবং pivoting না করা হয়, তাহলে divide by zero হয়।

◆ 14. এটি iterative না direct?

এটি একটি **direct method**, কারণ finite সংখ্যক ধাপে সঠিক সমাধান পাওয়া যায়।

◆ 15. Numerical stability কেমন?

Proper pivoting করলে stable, নইলে unstable হতে পারে।

◆ 16. Gauss Elimination কীভাবে computer program এ করা হয়?

Nested loops ব্যবহার করে elimination ও substitution অংশ আলাদা করে করা হয়। প্রতিটি pivot ধাপে matrix modify হয়।

◆ 17. কোন পদ্ধতিতে error control বেশি থাকে – Gauss না Gauss–Seidel?

Gauss–Seidel iterative বলে error control বেশি flexible, কিন্তু Gauss elimination এ fixed error accumulate হয়।

◆ 18. Coefficient matrix singular হলে কী হয়?

তখন elimination এর সময় division by zero হবে, অর্থাৎ সমাধান বের করা সম্ভব নয়।

◆ 19. এই পদ্ধতিতে কত ধাপ লাগে?

n সংখ্যক অজানা থাকলে, মোট $n-1$ elimination ধাপ লাগে।

◆ 20. কেন একে elimination method বলা হয়?

কারণ একে একে ভ্যারিয়েবল eliminate করে উপরের ত্রিভুজাকার ফর্মে আনা হয়।

◆ Viva Quick Recap Table:

প্রশ্ন	সংক্ষিপ্ত উত্তর
Gauss elimination কী?	লিনিয়ার সমীকরণ সমাধানের direct method
ধাপ কয়টা?	Elimination + Back substitution
Pivoting কেন লাগে?	Zero division এড়াতে ও error কমাতে
Complexity কত?	$O(n^3)$
অসুবিধা কী?	বড় সিস্টেমে slow ও rounding error
Gauss ও Gauss–Jordan এর পার্থক্য?	Jordan এ backward elimination ও হয়
Iterative না Direct?	Direct
Failure করে হয়?	Pivot zero হলে
Stability কেমন?	Pivoting থাকলে stable
ব্যবহার কোথায়?	Small/medium linear system solution

◆ 1. Gauss–Jordan Elimination Method কী?

Gauss–Jordan Elimination হলো একটা **direct method**, যা লিনিয়ার সমীকরণের সিস্টেম সমাধানে ব্যবহৃত হয়।

এখানে আমরা ম্যাট্রিক্সকে step-by-step **reduced row echelon form (RREF)** এ রূপান্তর করি — অর্থাৎ ম্যাট্রিক্সের বাম পাশে *identity matrix* পাই এবং ডানপাশে অজানাগুলোর মান।

◆ 2. এটি Gauss Elimination থেকে কিভাবে আলাদা?

Gauss Elimination এ forward elimination এর পর back substitution করতে হয়।

Gauss–Jordan এ **forward এবং backward elimination দুটোই হয়**, ফলে শেষে directভাবে solution পাওয়া যায় — back substitution লাগে না।

◆ 3. ধাপগুলো কীভাবে হয়?

- 1 প্রথমে augmented matrix তৈরি করা হয়: $[A|B][A|B][A|B]$ ।
 - 2 Pivot element কে 1 করা হয় (divide করে)।
 - 3 সেই কলামের অন্যসব element কে 0 করা হয় — pivot এর উপরে ও নিচে দুটো দিকেই।
 - 4 এইভাবে সব pivot কলামে কাজ করলে ম্যাট্রিক্স identity হয়ে যায়।
 - 5 ডান দিকের কলামে সরাসরি x, y, z, x, y, z এর মান পাওয়া যায়।
-

◆ 4. কেন backward elimination দরকার?

যাতে pivot কলামের উপরের মানগুলোও 0 হয়ে যায় — ফলে পুরো identity matrix তৈরি হয়।

◆ 5. এই পদ্ধতিতে back substitution লাগে কি?

না ❌, কারণ শেষে আমরা সরাসরি solution পাই।

◆ 6. Augmented matrix কী?

এটা হলো coefficient matrix AAA এবং constant matrix BBB একসাথে যুক্ত করে তৈরি করা ম্যাট্রিক্স:

$$[A|B][A|B][A|B]$$

◆ 7. Pivot element কী?

প্রত্যেক সারিতে leading nonzero element কে pivot বলে — সেটাকে ব্যবহার করে আমরা সারির অন্য মানগুলোকে 0 করি।

◆ 8. Pivot zero হলে কী হবে?

সেই সারি অন্য কোনো সারির সঙ্গে অদলবদল (row interchange) করতে হবে।

◆ 9. এই মেথডের সুবিধা কী?

- Back substitution লাগে না
 - সরাসরি solution পাওয়া যায়
 - Conceptually সহজ
-

◆ 10. অসুবিধা কী?

- বেশি computation লাগে
 - Large system এর জন্য slow
 - Rounding error accumulate করতে পারে
-

◆ 11. Complexity কত?

প্রায় $O(n^3)$ operations — Gauss elimination এর সমান, কিন্তু কিছুটা বেশি constant factor।

◆ 12. Numerical stability কেমন?

Pivot ছোট হলে বা zero হলে instability হতে পারে — তাই partial pivoting দরকার।

◆ 13. Gauss–Jordan এ pivot scaling দরকার হয় কেন?

যাতে বড় এবং ছোট সংখ্যার ratio এর কারণে numerical overflow/underflow না হয়।

◆ 14. Coefficient matrix singular হলে কী হবে?

যদি $|A| = 0$ হয়, তাহলে identity matrix পাওয়া সম্ভব নয় — সেক্ষেত্রে কোনো unique solution নেই।

◆ 15. Gauss–Jordan method কবে সবচেয়ে ভালো কাজ করে?

যখন সিস্টেম ছোট এবং accuracy দরকার — যেমন symbolic বা theoretical হিসাবের ক্ষেত্রে।

◆ 16. এই পদ্ধতিতে inverse বের করা যায় কি?

হ্যাঁ ☒, যদি augmented matrix $[A|I][A|I][A|I]$ নেওয়া হয়, তাহলে Gauss–Jordan প্রয়োগ করে আমরা $A^{-1}A^{-1}A^{-1}$ পেয়ে যাই।

◆ 17. এই method-এর অন্য নাম কী?

Reduced Row Echelon Method (RREF Method)।

◆ 18. Error control কেমন?

Pivoting থাকলে ভালো, নইলে rounding error propagate করতে পারে।

◆ 19. কেন direct method বলা হয়?

কারণ finite ধাপে exact solution দেয় — iteration লাগে না।

♦ 20. Viva তে জিজ্ঞেস করলে কীভাবে সংক্ষিপ্তভাবে বলবে:

“Gauss–Jordan হলো একটা direct elimination method যেখানে আমরা augmented matrix-কে reduced row echelon form-এ রূপান্তর করি এবং direct solution পাই, back substitution ছাড়াই।”

♦ 21. উদাহরণ:

ধরা যাক —

$$\begin{cases} x+y+z=6 \\ 2x+5y+z=-4 \\ 2x+3y+8z=27 \end{cases}$$

Augmented matrix বানাও, elimination করো → শেষে পাওয়া যাবে

$$x=3, y=5, z=-2$$

♦ 22. Gauss–Jordan এর output কী হয়?

Final matrix হয়:

$$[I|X]$$

যেখানে I = identity matrix এবং X = solution vector।

♦ Viva Recap Table:

প্রশ্ন	সংক্ষিপ্ত উত্তর
Gauss–Jordan কী?	লিনিয়ার সমীকরণ সমাধানের direct elimination method
Gauss elimination থেকে পার্থক্য? এখানে backward elimination-ও হয়	
Back substitution লাগে?	না
Augmented matrix কী?	$[A$
Pivot কী?	Leading element যেটা দিয়ে 0 করা হয়

প্রশ্ন	সংক্ষিপ্ত উত্তর
Pivot zero হলে?	Row interchange
সুবিধা	Direct solution, সহজ
অসুবিধা	বেশি computation, rounding error
Complexity	$O(n^3)$
ব্যবহার	Small system, matrix inverse বের করা

⚙ Iteration Methods — Viva Question & Answer (বাংলায়)

♦ 1. Iteration Method কী?

Iteration Method হলো এমন একটি পদ্ধতি যেখানে লিনিয়ার সমীকরণের সমাধান ধাপে ধাপে অনুমান করে বের করা হয়।

প্রথমে একটা প্রাথমিক অনুমান (initial guess) নেওয়া হয়, তারপর বারবার হিসাব করে মান refine করা হয় যতক্ষণ না error ছোট হয়।

♦ 2. Iteration Method কয় প্রকার?

মূলত দু'ধরনের —

1 Jacobi Method

2 Gauss–Seidel Method

♦ 3. Jacobi Method কীভাবে কাজ করে?

Jacobi Method এ প্রতিটি ভ্যারিয়েবলের নতুন মান হিসাব করা হয় শুধুমাত্র আগের iteration-এর মান ব্যবহার করে।

অর্থাৎ নতুন iteration শুরু করার আগে সব পুরনো মানই ব্যবহার করা হয়।

♦ 4. Gauss–Seidel Method কীভাবে আলাদা?

Gauss–Seidel Method এ প্রতিটি ভ্যারিয়েবল আপডেট করার সাথে সাথেই নতুন মান ব্যবহার করা হয় — ফলে দ্রুত convergence হয়।

◆ 5. Iteration Method-এর general ফর্ম কী?

ধরা যাক সিস্টেম:

$$a_{11}x + a_{12}y + a_{13}z = b_1$$

তাহলে

$$x = \frac{1}{a_{11}}(b_1 - a_{12}y - a_{13}z)$$

এই ফর্ম প্রতিটি ভ্যারিয়েবলের মান বারবার হিসাব করা হয়।

◆ 6. Convergence মানে কী?

Convergence মানে iteration যত বাড়ে, solution আস্তে আস্তে exact solution-এর কাছাকাছি চলে আসে।

◆ 7. Convergence condition কী?

Matrix যদি **diagonally dominant** হয় (অর্থাৎ প্রতিটি সারিতে প্রধান diagonal element এর মান সারির অন্য উপাদানের যোগফলের চেয়ে বড়), তাহলে method converge করে।

অর্থাৎ,

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad |a_{ii}| > \sum_{j \neq i} |a_{ij}|$$

◆ 8. Iteration এর stopping criterion কীভাবে ঠিক করা হয়?

যখন দুই successive iteration-এর মধ্যে পার্থক্য খুব ছোট হয়, যেমন

$$|x_i^{(k+1)} - x_i^{(k)}| < \epsilon$$

তখন iteration থামানো হয়।

◆ 9. Jacobi Method এর সুবিধা কী?

- Conceptually সহজ
 - সব equation একসাথে parallel করা যায় (কম্পিউটারে ভালো কাজ করে)
-

◆ 10. অসুবিধা কী?

- Convergence ধীর (slow)
 - সব equation একসাথে আপডেট করতে হয়
-

◆ 11. Gauss–Seidel Method এর সুবিধা কী?

- দ্রুত converge করে
 - Memory কম লাগে
 - Practically efficient
-

◆ 12. অসুবিধা কী?

- কিছু সিস্টেমে diverge করতে পারে
 - Equation এর order পরিবর্তন করলে effect পড়ে
-

◆ 13. Jacobi vs Gauss–Seidel পার্থক্য:

বিষয়	Jacobi	Gauss–Seidel
Update কবে হয় সবশেষে	সাথে সাথে	সাথে সাথে
Convergence	ধীর	দ্রুত
Memory	বেশি লাগে	কম লাগে
বাস্তব ব্যবহার	কম	বেশি

◆ 14. এই পদ্ধতি direct না iterative?

এগুলো **iterative method**, কারণ ধাপে ধাপে আনুমানিক সমাধান বের করা হয়।

◆ 15. Numerical Stability কেমন?

যদি matrix diagonally dominant হয়, তাহলে stable। না হলে error propagate করে।

◆ 16. প্রথমে initial guess কীভাবে নেওয়া হয়?

যেকোনো random বা zero assumption নেওয়া যায়, কিন্তু ভালো initial guess দিলে দ্রুত convergence হয়।

◆ 17. Iteration Method কবে ব্যর্থ হয়?

যদি system diagonally dominant না হয়, অথবা coefficient matrix ill-conditioned হয়।

◆ 18. Iteration এর error কীভাবে মাপা হয়?

$$E = \max_{1 \leq i \leq n} (|x_i(k+1) - x_i(k)|) \quad E = \max_{1 \leq i \leq n} (|x_i^{(k+1)} - x_i^{(k)}|) \quad E = \max (|x(k+1) - x(k)|)$$

এই maximum difference দিয়ে।

◆ 19. Computational cost কেমন?

প্রতি iteration এ প্রায় $O(n^2)$ operations লাগে।

◆ 20. কেন Iterative Method ব্যবহার করা হয়?

বড় সিস্টেমে direct method (Gauss elimination) অনেক memory ও time নেয় — Iterative method কম রিসোর্সে কাজ করে।

◆ 21. Jacobi Method কবে ব্যবহার উপযুক্ত?

যখন system symmetric এবং diagonally dominant।

◆ 22. Gauss–Seidel কবে ব্যবহার উপযুক্ত?

যখন দ্রুত convergence দরকার এবং previous iteration value সাথে সাথে ব্যবহার করা যাবে।

◆ 23. Relaxation factor কী?

একটা সংখ্যার সাহায্যে নতুন মান adjust করা হয়, যাতে convergence দ্রুত হয়।

$$x_{i\text{new}} = (1 - \omega)x_{i\text{old}} + \omega x_{i\text{computed}}$$
$$x_{i\text{new}} = (1 - \omega)x_{i\text{old}} + \omega x_{i\text{computed}}$$

এখানে $0 < \omega < 2$ $0 < \omega < 2$

◆ 24. Over-relaxation মানে কী?

যখন $\omega > 1$, তখন over-relaxation হয় — এতে কিছু ক্ষেত্রে দ্রুত convergence হয়।

◆ 25. Viva তে সংক্ষেপে বলার উপায়:

“Iteration Method হলো একটা পুনরাবৃত্তি-ভিত্তিক পদ্ধতি যেখানে লিনিয়ার সমীকরণের সমাধান successive approximation দ্বারা বের করা হয়। Jacobi ও Gauss–Seidel সবচেয়ে সাধারণ, যেখানে diagonal dominance থাকলে convergence নিশ্চিত।”

◆ Viva Quick Recap Table:

প্রশ্ন	সংক্ষিপ্ত উত্তর
Iteration method কী?	Repeated approximation দ্বারা সমাধান
কি ধরনের?	Jacobi ও Gauss–Seidel
Convergence শর্ত?	Diagonal dominance

প্রশ্ন

সংক্ষিপ্ত উত্তর

Jacobi ধীর কেন?	পুরনো মান ব্যবহার করে
Gauss–Seidel দ্রুত কেন? সাথে সাথে নতুন মান ব্যবহার করে	
Direct না Iterative?	Iterative
Error কিভাবে মাপা হয়?	Successive difference দ্বারা
Failure কবে হয়?	Non-dominant matrix এ
Relaxation factor কী?	Convergence adjust করার ফ্যাক্টর
Over-relaxation?	$\omega > 1$ হলে

⚙ Iteration Methods — Viva Question & Answer (বাংলায়)

◆ 1. Iteration Method কী?

Iteration Method হলো এমন একটি পদ্ধতি যেখানে লিনিয়ার সমীকরণের সমাধান ধাপে ধাপে অনুমান করে বের করা হয়।

প্রথমে একটা প্রাথমিক অনুমান (initial guess) নেওয়া হয়, তারপর বারবার হিসাব করে মান refine করা হয় যতক্ষণ না error ছোট হয়।

◆ 2. Iteration Method কয় প্রকার?

মূলত দু'ধরনের —

1 Jacobi Method

2 Gauss–Seidel Method

◆ 3. Jacobi Method কীভাবে কাজ করে?

Jacobi Method এ প্রতিটি ভ্যারিয়েবলের নতুন মান হিসাব করা হয় শুধুমাত্র আগের iteration-এর মান ব্যবহার করে।

অর্থাৎ নতুন iteration শুরু করার আগে সব পুরনো মানই ব্যবহার করা হয়।

◆ 4. Gauss–Seidel Method কীভাবে আলাদা?

Gauss–Seidel Method এ প্রতিটি ভ্যারিয়েবল আপডেট করার সাথে সাথেই নতুন মান ব্যবহার করা হয় — ফলে দ্রুত convergence হয়।

◆ 5. Iteration Method-এর general ফর্ম কী?

ধরা যাক সিস্টেম:

$$a_{11}x + a_{12}y + a_{13}z = b_1$$

তাহলে

$$x = \frac{1}{a_{11}}(b_1 - a_{12}y - a_{13}z)$$

এই ফর্মে প্রতিটি ভ্যারিয়েবলের মান বারবার হিসাব করা হয়।

◆ 6. Convergence মানে কী?

Convergence মানে iteration যত বাড়ে, solution আস্তে আস্তে exact solution-এর কাছাকাছি চলে আসে।

◆ 7. Convergence condition কী?

Matrix যদি **diagonally dominant** হয় (অর্থাৎ প্রতিটি সারিতে প্রধান diagonal element এর মান সারির অন্য উপাদানের যোগফলের চেয়ে বড়), তাহলে method converge করে।

অর্থাৎ,

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \forall i$$

◆ 8. Iteration এর stopping criterion কীভাবে ঠিক করা হয়?

যখন দুই successive iteration-এর মধ্যে পার্থক্য খুব ছোট হয়, যেমন

$$|x_{i(k+1)} - x_{i(k)}| < \epsilon \quad |x_{i(k+1)} - x_{i(k)}| < \epsilon$$

তখন iteration থামানো হয়।

◆ 9. Jacobi Method এর সুবিধা কী?

- Conceptually সহজ
- সব equation একসাথে parallel করা যায় (কম্পিউটারে ভালো কাজ করে)

◆ 10. অসুবিধা কী?

- Convergence ধীর (slow)
- সব equation একসাথে আপডেট করতে হয়

◆ 11. Gauss–Seidel Method এর সুবিধা কী?

- দ্রুত converge করে
- Memory কম লাগে
- Practically efficient

◆ 12. অসুবিধা কী?

- কিছু সিস্টেমে diverge করতে পারে
- Equation এর order পরিবর্তন করলে effect পড়ে

◆ 13. Jacobi vs Gauss–Seidel পার্থক্য:

বিষয়	Jacobi	Gauss–Seidel
-------	--------	--------------

Update করে হয় সবশেষে	সাথে সাথে	
-----------------------	-----------	--

বিষয়	Jacobi	Gauss–Seidel
Convergence	ধীর	দ্রুত
Memory	বেশি লাগে	কম লাগে
বাস্তব ব্যবহার	কম	বেশি

◆ 14. এই পদ্ধতি direct না iterative?

এগুলো **iterative method**, কারণ ধাপে ধাপে আনুমানিক সমাধান বের করা হয়।

◆ 15. Numerical Stability কেমন?

যদি matrix diagonally dominant হয়, তাহলে stable। না হলে error propagate করে।

◆ 16. প্রথমে initial guess কীভাবে নেওয়া হয়?

যেকোনো random বা zero assumption নেওয়া যায়, কিন্তু ভালো initial guess দিলে দ্রুত convergence হয়।

◆ 17. Iteration Method কবে ব্যর্থ হয়?

যদি system diagonally dominant না হয়, অথবা coefficient matrix ill-conditioned হয়।

◆ 18. Iteration এর error কীভাবে মাপা হয়?

$$E = \max_{1 \leq i \leq n} (|x_i^{(k+1)} - x_i^{(k)}|) \quad E = \max(|x^{(k+1)} - x^{(k)}|) \quad E = \max(|x^{(k+1)} - x^{(k)}|)$$

এই maximum difference দিয়ে।

◆ 19. Computational cost কেমন?

প্রতি iteration এ প্রায় $O(n^2)$ operations লাগে।

♦ 20. কেন Iterative Method ব্যবহার করা হয়?

বড় সিস্টেমে direct method (Gauss elimination) অনেক memory ও time নেয় — Iterative method কম রিসোর্সে কাজ করে।

♦ 21. Jacobi Method কবে ব্যবহার উপযুক্ত?

যখন system symmetric এবং diagonally dominant।

♦ 22. Gauss–Seidel কবে ব্যবহার উপযুক্ত?

যখন দ্রুত convergence দরকার এবং previous iteration value সাথে সাথে ব্যবহার করা যাবে।

♦ 23. Relaxation factor কী?

একটা সংখ্যার সাহায্যে নতুন মান adjust করা হয়, যাতে convergence দ্রুত হয়।

$$x_{i\text{new}} = (1 - \omega)x_{i\text{old}} + \omega x_{i\text{computed}}$$
$$x_{i\text{new}} = (1 - \omega)x_{i\text{old}} + \omega x_{i\text{computed}}$$

এখানে $0 < \omega < 2$

♦ 24. Over-relaxation মানে কী?

যখন $\omega > 1$, তখন over-relaxation হয় — এতে কিছু ক্ষেত্রে দ্রুত convergence হয়।

♦ 25. Viva তে সংক্ষেপে বলার উপায়:

“Iteration Method হলো একটা পুনরাবৃত্তি-ভিত্তিক পদ্ধতি যেখানে লিনিয়ার সমীকরণের সমাধান successive approximation দ্বারা বের করা হয়। Jacobi ও Gauss–Seidel সবচেয়ে সাধারণ, যেখানে diagonal dominance থাকলে convergence নিশ্চিত।”

♦ Viva Quick Recap Table:

প্রশ্ন	সংক্ষিপ্ত উত্তর
Iteration method কী?	Repeated approximation দ্বারা সমাধান
কিটি ধরনের?	Jacobi ও Gauss–Seidel
Convergence শর্ত?	Diagonal dominance
Jacobi ধীর কেন?	পুরনো মান ব্যবহার করে
Gauss–Seidel দ্রুত কেন?	সাথে সাথে নতুন মান ব্যবহার করে
Direct না Iterative?	Iterative
Error কিভাবে মাপা হয়?	Successive difference দ্বারা
Failure কবে হয়?	Non-dominant matrix এ
Relaxation factor কী?	Convergence adjust করার ফ্যাক্টর
Over-relaxation?	$\omega > 1$ হলে

তুমি যদি বলো “**next**”, আমি এখন পরের টপিক **Root-Finding Methods** শুরু করব — (Bisection, Regula-Falsi, Newton–Raphson সব একসাথে, viva-ready করে বাংলায়)। চলবো?

You said:

ok

ChatGPT said:

দারুণ ভাই 🤓 এখন আমরা চলে যাবি সবচেয়ে গুরুত্বপূর্ণ অংশে —

◆ Root-Finding Methods — Viva Q&A (বাংলায় সব ব্যাখ্যা সহ)

এই টপিকটা viva-তে প্রায়ই আসে, তাই ভালো করে মুখস্থ রাখো।

এখানে আমরা নেব 👉 **Bisection Method, False Position (Regula Falsi), আর Newton–Raphson Method** — একসাথে সব প্রশ্ন-উত্তর।

1 Root-Finding Basics

◆ 1. Root-finding method কী?

যে পদ্ধতিতে কোনো ফাংশনের $f(x)=0$ সমীকরণের জন্য x -এর মান নির্ণয় করা হয়, তাকে root-finding method বলে।

◆ 2. Analytical ও Numerical Root-Finding এর পার্থক্য কী?

- Analytical: exact algebraic সমাধান (যেমন, ফ্যাক্টরাইজেশন)।
 - Numerical: আনুমানিক (approximate) সমাধান, iteration করে বের করা হয়।
-

◆ 3. কেন numerical method দরকার হয়?

যখন $f(x)$ জটিল বা transcendental (যেমন $\sin x = x$), তখন exact root বের করা সম্ভব হয় না, তাই numerical method লাগে।

2 Bisection Method

◆ 4. Bisection Method কীভাবে কাজ করে?

এটা একটা **bracketing method**, যেখানে আমরা এমন দুটি পয়েন্ট a এবং b নিই যাতে

$$f(a) \cdot f(b) < 0$$

অর্থাৎ root ওই interval-এ আছে।

তারপর interval টা বারবার অর্ধেক করা হয় যতক্ষণ না root পাওয়া যায়।

◆ 5. সূত্র কী?

$$x_{mid} = \frac{a + b}{2}$$

যদি $f(a) \cdot f(x_{mid}) < 0$, তাহলে নতুন interval হবে $[a, x_{mid}]$

না হলে $[x_{mid}, b]$

◆ 6. Stopping criterion কী?

যখন interval এর দৈর্ঘ্য খুব ছোট হয় বা

$$|f(x_{mid})| < \epsilon \quad |f(x_{mid})| < \epsilon$$

তখন iteration থামানো হয়।

◆ 7. সুবিধা কী?

- খুবই সহজ
 - সবসময় converge করে
 - Root guaranteed (bracketing আছে)
-

◆ 8. অসুবিধা কী?

- Convergence ধীর
 - Derivative ব্যবহার করা হয় না
 - প্রতি ধাপে মাত্র ১টি root interval এ দেখা যায়
-

◆ 9. এটা open না closed method?

Closed (bracketing) method।

◆ 10. Convergence rate কত?

Linear convergence — ধীরে ধীরে root এর দিকে যায়।

3 False Position Method (Regula Falsi)

◆ 11. Regula-Falsi কীভাবে কাজ করে?

এটাও bracketing method, কিন্তু এখানে midpoint না নিয়ে আমরা straight line approximation ব্যবহার করি।

◆ 12. সূত্র কী?

$$x_{\text{new}} = \frac{a f(b) - b f(a)}{f(b) - f(a)}$$

◆ 13. ধারণা কী?

$(a, f(a))$ ও $(b, f(b))$ পয়েন্টের মাঝে সরল রেখা টানা হয়, তার সাথে x-axis এর ছেদবিন্দু হলো নতুন root approximation।

◆ 14. সুবিধা কী?

- Faster than Bisection
 - Guaranteed convergence
 - Easy to apply
-

◆ 15. অসুবিধা কী?

- কিছু ক্ষেত্রে one-sided convergence (এক দিকের point fix হয়ে যায়)
 - Slow if $f(x)$ highly nonlinear
-

◆ 16. Convergence nature কী?

Faster than linear but slower than Newton–Raphson।

◆ 17. Bisection vs Regula-Falsi পার্থক্য:

বিষয়	Bisection	Regula-Falsi
Approach	Midpoint	Line intersection

বিষয়	Bisection	Regula-Falsi
Speed	Slow	Faster
Guarantee	Always	Always
Error rate	Constant halving	Variable

⚡ 🔑 Newton–Raphson Method

♦ 18. Newton–Raphson Method কীভাবে কাজ করে?

এটা একটা **open method**, যেখানে tangent line এর সাহায্যে root বের করা হয়।
প্রথমে একটি initial guess x_0 নেই, তারপর সূত্র ব্যবহার করে নতুন মান পাই।

♦ 19. সূত্র কী?

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} \quad x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

♦ 20. Geometric ধারণা কী?

ফাংশনের x_n বিন্দুতে ট্যাংজেন্ট টানা হয়, এবং সেই ট্যাংজেন্ট x-axis কে যেখানে ছেদ করে, সেটিই পরের approximation।

♦ 21. সুবিধা কী?

- খুব দ্রুত convergence (quadratic)
 - কম iteration লাগে
 - Simple to implement (if derivative known)
-

♦ 22. অসুবিধা কী?

- $f'(x)$ জানা থাকতে হবে
- Initial guess ভুল হলে diverge করতে পারে

- $f'(x)=0$ হলে fail হয়

♦ 23. Convergence rate কত?

Quadratic — খুব দ্রুত converge করে।

♦ 24. Derivative প্রয়োজন কেন?

কারণ tangent line-এর ঢাল ব্যবহার করে আমরা পরবর্তী root estimate করি।

♦ 25. এটি open না closed method?

Open method — initial guess লাগে, interval লাগে না।

♦ 26. Newton–Raphson এর failure কবে হয়?

যদি tangent x-axis এর parallel হয় (অর্থাৎ $f'(x_n)=0$), তখন।

♦ 27. এই মেথডের প্রয়োগ কোথায়?

Engineering problems, control systems, nonlinear equation solving, etc.

♦ 28. Viva তে short answer:

“Newton–Raphson হলো একটা open root-finding method যেখানে tangent line ব্যবহার করে successive approximation এর মাধ্যমে root বের করা হয়।”

♦ 29. তিনটা method এর তুলনা:

পদ্ধতি	টাইপ	Derivative লাগে?	Speed	Stability
Bisection	Closed	না	Slow	Always stable
Regula-Falsi	Closed	না	Medium	Stable

পদ্ধতি	টাইপ	Derivative লাগে?	Speed	Stability
Newton–Raphson	Open	হ্যাঁ	Very fast	Depends on guess

♦ 30. Viva Quick Recap Table

প্রশ্ন	সংক্ষিপ্ত উত্তর
Root-finding কী?	$f(x)=0$ সমাধানের পদ্ধতি
Bisection method কী?	Interval halve করে root বের করা
Regula-Falsi কীভাবে কাজ করে?	Line intersection দ্বারা root
Newton–Raphson সূত্র?	$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$
Convergence rate?	Linear (Bisection), Quadratic (NR)
Open/Closed method?	Bisection – Closed, NR – Open
Derivative কবে লাগে?	Newton–Raphson এ
Failure কবে?	$f'(x)=0$ বা guess ভুল হলে
কোনটা সবচেয়ে fast?	Newton–Raphson
কোনটা সবচেয়ে safe?	Bisection

✖ 1 Interpolation Basics

♦ 1. Interpolation কী?

যে পদ্ধতিতে কোনো ফাংশনের অজানা মান নির্ণয় করা হয় দেওয়া data points এর মধ্যে, তাকে Interpolation বলে।

◆ 2. কেন Interpolation লাগে?

- যখন function-এর পূর্ণ আকার জানা নেই, কিন্তু কিছু data points আছে
- মধ্যবর্তী মান (intermediate value) বের করতে

◆ 3. Interpolation vs Extrapolation পার্থক্য কী?

- Interpolation: data points-এর মধ্যে মান বের করা
- Extrapolation: data points-এর বাইরে মান অনুমান করা (risk বেশি)

2 Newton's Forward & Backward Difference Interpolation

◆ 4. Newton Forward Difference Method কী?

- সমান spacing হলে data table-এর ওপর forward difference ব্যবহার করে polynomial বানানো হয়।

$$f(x) = f_0 + p\Delta f_0 + \frac{p(p-1)}{2!}\Delta^2 f_0 + \dots$$
$$f(x) = f_0 + p\Delta f_0 + \frac{p(p-1)}{2!}\Delta^2 f_0 + \dots$$

$$\text{যেখানে } p = \frac{x - x_0}{h}$$

◆ 5. Newton Backward Difference Method কী?

- শেষ point থেকে শুরু করে backward differences ব্যবহার।

$$f(x) = f_n + p\nabla f_n + \frac{p(p+1)}{2!}\nabla^2 f_n + \dots$$
$$f(x) = f_n + p\nabla f_n + \frac{p(p+1)}{2!}\nabla^2 f_n + \dots$$

$$\text{যেখানে } p = \frac{x - x_n}{h}$$

◆ 6. কোনটি কবে ব্যবহার হয়?

- Forward: যখন x data শুরু থেকে কাছাকাছি
- Backward: যখন x data শেষের কাছাকাছি

◆ 7. Advantage & Disadvantage

সুবিধা

অসুবিধা

সহজ, systematic

সমান spacing দরকার

Error easily estimated High degree polynomial হলে oscillation

◆ 8. Viva trick: Δ ও ∇ পার্থক্য?

- Δ = forward difference ($\Delta f_n = f_{n+1} - f_n$)
- ∇ = backward difference ($\nabla f_n = f_n - f_{n-1}$)

◆ 9. Error formula কী?

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x-x_0)(x-x_1)\dots(x-x_n)$$

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x-x_0)(x-x_1)\dots(x-x_n)$$



3 Lagrange Interpolation

◆ 10. Lagrange Interpolation কী?

- Unequally spaced points-এর জন্য suitable

$$P_n(x) = \sum_{i=0}^n y_i L_i(x)$$

$$P_n(x) = \sum_{i=0}^n y_i L_i(x)$$

যেখানে

$$L_i(x) = \prod_{j=0, j \neq i}^n \frac{x - x_j}{x_i - x_j}$$

$$L_i(x) = \prod_{j=0, j \neq i}^n \frac{x - x_j}{x_i - x_j}$$

◆ 11. Advantage

- Unequally spaced points handle করে
- কোনো difference table দরকার নেই

◆ 12. Disadvantage

- High degree polynomial → Runge phenomenon
- প্রতি নতুন point added করলে পুরো formula পরিবর্তন করতে হয়

◆ 13. Error formula

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x-x_0)(x-x_1)\dots(x-x_n)$$
$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x-x_0)(x-x_1)\dots(x-x_n)$$

◆ 14. Viva short answer: Forward vs Backward vs Lagrange

বিষয়	Forward	Backward	Lagrange
Data spacing	Equal	Equal	Unequal
Formula	Δ based	∇ based	$L_i(x)$
Advantage	Easy for start	Easy for end	Flexible nodes
Disadvantage	Only equal spacing	Only equal spacing	High degree instability

◆ 15. Viva trick:

“Newton Forward Difference তখন use করবে যখন point start-এর কাছে, backward যখন end-এর কাছে, আর Lagrange যখন spacing unequal।”

◆ 16. Convergence/Accuracy কীভাবে দেখা যায়?

- Error term দ্বারা
- Degree বেশি হলে error কম না হতে পারে → Runge phenomenon

◆ 17. Step-by-step Example (exam-ready):

Data: $x = 0, 1, 2$; $y = 1, 3, 7$

Newton Forward:

$\Delta y_0 = 3 - 1 = 2, \Delta^2 y_0 = 7 - 2 - 1 = 4$? $\Delta y_0 = 3 - 1 = 2, \Delta^2 y_0 = 7 - 2 - 1 = 4$? $\Delta y_0 = 3 - 1 = 2, \Delta^2 y_0 = 7 - 2 - 1 = 4$? (short version for viva)

পরে formula বসিয়ে $x = 1.5$ estimate করা যায়।

◆ 18. Viva short Q&A

প্রশ্ন	উত্তর (বাংলা)
Interpolation কী?	Known points-এর মধ্যে function মান বের করা
Newton Forward কবে ব্যবহার?	Start point কাছাকাছি
Newton Backward কবে ব্যবহার?	End point কাছাকাছি
Δ এবং ∇ পার্থক্য?	Δ = forward, ∇ = backward difference
Lagrange কবে ব্যবহার?	Unequal spacing points
Error formula?	$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod (x - x_i)$ $R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod (x - x_i)$
Disadvantage Newton?	শুধু সমান spacing, high degree instability
Disadvantage Lagrange?	High degree polynomial, full formula পরিবর্তন
Viva trick?	Forward start, Backward end, Lagrange unequal

1 Numerical Integration Basics

1. Numerical Integration কী?

যখন function $f(x)$ এর analytical integration কঠিন বা অসম্ভব, তখন approximate value বের করার পদ্ধতিকে numerical integration বলে।

2. কেন লাগে?

- Complex বা transcendental functions
- Data points থেকে area under curve বের করতে

3. Exact vs Numerical Integration পার্থক্য

- Exact: analytical formula দ্বারা $\int_a^b f(x) dx$ বের করা
- Numerical: approximate, finite steps ব্যবহার করে

2 Trapezoidal Rule

4. Trapezoidal Rule কীভাবে কাজ করে?

Curve কে ছোট ছোট trapezoids-এ approximate করে integral বের করা হয়।

$$\int_a^b f(x) dx \approx h \left[\frac{f(x_0) + f(x_n)}{2} + \sum_{i=1}^{n-1} f(x_i) \right]$$

যেখানে $h = \frac{b-a}{n}$, n = subintervals

5. সুবিধা

- সহজ, সরাসরি
- Small n -এর জন্য acceptable

6. অসুবিধা

- Accuracy low, especially high curvature
- Step size ছোট করতে হয়

7. Convergence nature

Error proportional to h^2 → second order

8. Viva trick

- Area under curve trapezoids দিয়ে approximate করা
- Linear interpolation between points



3 Simpson's 1/3 Rule

9. Simpson's 1/3 Rule কী?

- Interval 2 ভাগে ভাগ করা হয় (even number of subintervals)
- Curve approximate করা হয় quadratic polynomial দ্বারা

$$\int_a^b f(x) dx \approx \frac{h}{3} [f_0 + 4f_1 + 2f_2 + 4f_3 + \dots + f_n]$$

10. সুবিধা

- Accuracy বেশি (trapezoid এর চেয়ে)
- Smooth curve approximation

11. অসুবিধা

- Subintervals even number হতে হবে
- Step size অনেক ছোট হলে computation বেশি

12. Error

Proportional to h^4 → **fourth order**



4 Simpson's 3/8 Rule

13. Simpson's 3/8 Rule কী?

- Interval 3 ভাগে ভাগ করা হয়

$$\int_a^b f(x) dx \approx \frac{3h}{8} [f_0 + 3f_1 + 3f_2 + 2f_3 + 3f_4 + \dots + f_n]$$

- 3 subintervals-wise cubic approximation

14. সুবিধা

- Higher order approximation
- Odd number of subintervals handle করে

15. অসুবিধা

- Formula একটু জটিল

♦ **5 Comparison Table (viva-friendly)**

পদ্ধতি	Subinterval	Approximation	Error order	Advantage	Disadvantage
Trapezoidal	Any	Linear	h^2	Easy, simple	Low accuracy
Simpson 1/3	Even	Quadratic	h^4	Better accuracy	Even subinterval needed
Simpson 3/8	Multiple of 3	Cubic	h^4	Handles odd	Formula complex

♦ **6 Viva Short Q&A Table**

প্রশ্ন	উত্তর (বাংলা)
Numerical integration কী?	Function কে approximate করে area বা integral বের করা
Trapezoidal rule কেমন?	Trapezoids দিয়ে linear approximation, error $O(h^2)$
Simpson 1/3 rule কেমন?	Quadratic approximation, error $O(h^4)$, even subintervals
Simpson 3/8 rule কেমন?	Cubic approximation, subinterval multiple of 3
Trapezoid vs Simpson?	Simpson বেশি accurate
Subinterval সংখ্যা কেমন হতে হবে?	$1/3 \rightarrow$ even, $3/8 \rightarrow$ multiple of 3
Error proportionality?	Trapezoid h^2 , Simpson h^4

♦ **7 Viva Tip**

- Integral ঐ pattern দেখে quick identification
- Small $n \rightarrow$ Trapezoid, Medium $\rightarrow$ Simpson 1/3, Larger or uneven $\rightarrow$ Simpson 3/8

1 Basics: Regression & Curve Fitting কী

◆ 1. Curve fitting কী?

যে পদ্ধতিতে দেওয়া data points-এর মধ্য দিয়ে যাওয়া বা তাদের সবচেয়ে কাছাকাছি কোনো mathematical curve তৈরি করা হয়, তাকে curve fitting বলে।

◆ 2. Regression কী?

Regression হলো statistical approach যেটা দিয়ে dependent variable (y) ও independent variable (x)-এর সম্পর্ক নির্ণয় করা হয়।

◆ 3. Curve fitting এর উদ্দেশ্য কী?

- Data থেকে relation বের করা
- Prediction বা estimation করা
- Data visualization smooth করা

◆ 4. Curve fitting এর প্রকারভেদ

1 Linear fitting

2 Polynomial fitting

3 Exponential fitting

4 Logarithmic fitting

5 Logistic regression

◆ 5. Regression ও Interpolation পার্থক্য কী?

বিষয়	Regression	Interpolation
Data points	Approximate	Exact (সব পয়েন্টে যায়)
Error	Minimize করা হয় শূন্য	
Use	Trend analysis	Intermediate value বের করা



2 Least Squares Method

◆ 6. Least Squares Method কীভাবে কাজ করে?

এটা curve fitting-এর সবচেয়ে সাধারণ পদ্ধতি, যেখানে sum of squared errors (residuals) **minimum** করা হয়।

$$\text{Minimize } \sum (y_i - \hat{y}_i)^2 \quad \text{Minimize } \sum (y_i - \hat{y}_i)^2$$

◆ 7. Principle কী?

$$\text{Error } E = y - \hat{y} \quad E = y - \hat{y}$$

We minimize $\sum E^2$ so that total deviation is least.

◆ 8. Linear Equation Form (for straight line):

ধরা যাক curve হলো $y = a + bx$

তাহলে আমরা দুইটা equation পাই —

$$\sum y = na + b \sum x \quad \sum xy = a \sum x + b \sum x^2$$

এগুলো solve করে aaa (intercept) ও bbb (slope) বের করা হয়।

◆ 9. সুবিধা

- Simple to compute
- Minimum error নিশ্চিত
- Applicable to all types of regression

◆ 10. অসুবিধা

- Linear assumption দরকার
- Outlier sensitive

3 Linear Regression

◆ 11. Linear Regression কী?

যখন dependent variable (y) ও independent variable (x)-এর মধ্যে linear সম্পর্ক থাকে।

$$y = a + bx$$

◆ 12. এখানে a ও b কী?

- aaa: intercept (যেখানে $x=0$, y এর মান)
- bbb: slope (x পরিবর্তনে y কত পরিবর্তন হয়)

◆ 13. Viva formula স্মরণ রাখো:

$$b = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2} \quad a = \frac{\sum y}{n} - b \frac{\sum x}{n}$$

◆ 14. Advantage

- সহজ, widely used
- Trend analysis বা prediction-এর জন্য perfect

◆ 15. Disadvantage

- শুধুমাত্র linear relation-এর জন্য
- Complex data handle করতে পারে না

Polynomial Regression

◆ 16. Polynomial Regression কী?

যখন relationship nonlinear, তখন higher degree polynomial ব্যবহার করা হয় —

$$y=a+bx+cx^2+dx^3+\dots y = a + bx + cx^2 + dx^3 + \dots y=a+bx+cx^2+dx^3+\dots$$

◆ 17. ব্যবহার

- Nonlinear data trend
- Scientific data modeling

◆ 18. Advantage

- Flexible, better fitting
- Complex patterns handle করে

◆ 19. Disadvantage

- High degree হলে overfitting
- Computation heavy

⚡ 5 Logistic Regression

◆ 20. Logistic Regression কী?

Binary classification (হ্যাঁ/না, 0/1) ধরনের prediction-এর জন্য regression, যেখানে output limited থাকে 0 থেকে 1-এর মধ্যে।

$$P = \frac{1}{1 + e^{-(a + bx)}} \quad P = \frac{1}{1 + e^{-(a + bx)}}$$

◆ 21. Conceptual Idea

Output probability আকারে আসে, linear না — S-shaped (sigmoid) curve।

◆ 22. ব্যবহার

- Machine Learning

- Population growth
- Yes/No outcome prediction

◆ 23. Advantage

- Binary/Probabilistic data handle করে
- Statistical stability

◆ 24. Disadvantage

- শুধু categorical outcome
- Complex model derive করতে হয়

6 Curve Fitting & Regression Comparison Summary

Method	Equation	Type	Advantage	Disadvantage
Linear	$y = a + bx$	Simple linear	Easy	Limited
Polynomial	$y = a + bx + cx^2 \dots$	Nonlinear	Flexible	Overfit risk
Logistic	$P = 1 / (1 + e^{-(a-bx)})$	Classification	Probabilistic	Complex math
Least Squares	$\sum (y - \hat{y})^2 \min$	General	Accurate fitting	Sensitive to outlier

7 Viva Short Q&A Recap

প্রশ্ন	উত্তর (বাংলা)
Curve fitting কী?	Data-এর কাছাকাছি mathematical curve
Regression কী?	Dependent ও independent variable এর সম্পর্ক
Least Squares কী?	Error square minimize করে best fit line

প্রশ্ন	উত্তর (বাংলা)
Linear regression সূত্র?	$y = a + bx$
Polynomial regression কবে লাগে?	Nonlinear data
Logistic regression কবে লাগে?	Binary outcome (0/1)
a ও b কী বোঝায়?	$a \rightarrow$ intercept, $b \rightarrow$ slope
Regression vs Interpolation পার্থক্য?	Regression approximate, Interpolation exact
Overfitting কী?	বেশি degree polynomial এ data overmatch করা
Viva trick	Linear সহজ, Polynomial flexible, Logistic probabilistic

Optimization & Learning — Viva Q&A (বাংলায়)

(মূল ফোকাস: Stochastic Gradient Descent – SGD)

1 Optimization Basics

1. Optimization কী?

Optimization হলো এমন প্রক্রিয়া যেখানে কোনো function-এর **minimum** বা **maximum** মান বের করা হয় — যাতে result সর্বোত্তম (optimal) হয়।

2. Numerical Optimization কেন দরকার?

অনেক ফাংশনের exact derivative বা analytical solution বের করা যায় না, তাই numerical পদ্ধতি ব্যবহার করে approximate minimum বের করা হয়।

3. Optimization এর প্রকারভেদ:

- Unconstrained optimization
- Constrained optimization
- Deterministic
- Stochastic



2 Gradient Descent Method

4. Gradient Descent কীভাবে কাজ করে?

Gradient Descent এমন একটা iterative পদ্ধতি, যেখানে আমরা function $f(x)$ -এর মান কমাতে চাই।

প্রতিটি ধাপে x আপডেট করা হয় —

$$x_{\text{new}} = x_{\text{old}} - \eta \frac{df}{dx}$$

এখানে

- η = learning rate (step size)
- $\frac{df}{dx}$ = slope বা gradient

5. ধারণা (Intuition):

- আমরা slope এর বিপরীত দিকে যাই (because gradient $\rightarrow$ direction of increase)।
- ধাপে ধাপে নিচের দিকে নামলে (minimum এ পৌঁছাই) function minimize হয়।

6. Advantage:

- Simple and efficient for differentiable functions
- Widely used in machine learning

7. Disadvantage:

- Step size ভুল হলে diverge করতে পারে
- Local minima তে আটকে যেতে পারে



3 Stochastic Gradient Descent (SGD)

8. SGD কী?

যখন dataset বড়, তখন পুরো data একসাথে না নিয়ে, একটা বা কিছু sample ব্যবহার করে parameter আপডেট করা হয় — এটিই Stochastic Gradient Descent।

9. SGD এর Formula:

$$\theta_{\text{new}} = \theta_{\text{old}} - \eta \nabla_{\theta} J(\theta; x_i, y_i) \\ \theta_{\text{new}} = \theta_{\text{old}} - \eta \nabla_{\theta} J(\theta; x_i, y_i)$$

যেখানে J হলো cost function (loss), এবং (x_i, y_i) হলো single sample।

10. কেন “Stochastic”?

কারণ প্রতিবার update করার সময় random subset (mini-batch বা single data point) নেওয়া হয়, ফলে randomness থাকে।

11. SGD vs Batch Gradient Descent পার্থক্য

বিষয়	Batch GD	Stochastic GD
Data used	Full dataset	One sample (or mini batch)
Speed	Slow	Fast
Stability	Smooth	Noisy updates
Memory need বেশি	কম	
Convergence	Steady	Fluctuating but quicker

12. Advantage:

- Large dataset-এ efficient
- Online learning-এর জন্য perfect
- Fast convergence (initially)

13. Disadvantage:

- Noisy gradient update
- Step-to-step oscillation হতে পারে

4 Learning Rate (η)

14. Learning Rate কী?

η (eta) হলো step size — gradient অনুযায়ী কতটা move করবে তা নির্ধারণ করে।

- η বেশি $\rightarrow$ overshoot (diverge)
- η কম $\rightarrow$ ধীরে converge

15. Adaptive learning rate কী?

যখন η iteration-এর সাথে সাথে adjust হয় (যেমন Adam, RMSProp methods)।

5 Cost Function

16. Cost Function কী?

Function $J(\theta)$ যেটা minimize করা হয় — model কতটা ভালো করছে তা measure করে (error measure)।

উদাহরণ:

$$J(\theta) = \frac{1}{2m} \sum (h_{\theta}(x_i) - y_i)^2$$

17. SGD এর লক্ষ্য কী?

Cost function-এর মান minimum করা — অর্থাৎ model এর error যতটা সম্ভব কম করা।